Previsão de Temperatura e Detecção de Eventos de Chuva Forte em uma Rede Meteorológica Urbana com GraphSAGE

Vinícius Pereira Rodrigues
Faculdade de Computação e Informática
Universidade Presbiteriana Mackenzie
São Paulo, Brasil
viniciuspereira.rodrigues1@mackenzista.com.br

Ivan Carlos Alcântara de Oliveira
Faculdade de Computação e Informática
Universidade Presbiteriana Mackenzie
São Paulo, Brasil
ivan.oliveira@mackenzie.br

***Abstract*—Extreme rainfall causes recurrent flooding and material losses in the Metropolitan Area of São Paulo. We model 35 weather stations of the region as a graph weighted by geographic proximity, reconstruct the series of stations without usable historical records via Feature Propagation, and train a GraphSAGE network to forecast rainfall and temperature 60 minutes ahead (training on 2016–2022, validating on 2023 and testing on 2024). Unlike existing approaches that address spatial reconstruction, weather forecasting, and anomaly detection as separate tasks, the proposed architecture integrates all three within a unified graph-based pipeline for urban meteorological networks. Temperature is forecast with high fidelity (0.97 correlation and RMSE below persistence), a gain for which the ablation experiments indicate a contribution of the graph structure. The evaluated models did not achieve satisfactory performance in forecasting heavy-rain magnitude under the conditions of this experiment, a limitation highlighted by the analysis of rainfall increments in heavy-rain windows; an STGCN trained on a two-hour window cuts temperature RMSE by a further 38% while heavy-rain peaks remain underestimated. For precipitation, the system is assessed as a retrospective detector based on a multivariate Mahalanobis score over prediction errors. In the retrospective evaluation aggregated by day and over the network, the detector reached 100% recall on the 80 positive days of 2024, but with 21.9% precision and 0% specificity, flagging every day of the period. Evaluated per station and 60-minute window, recall was approximately 48% with 20% precision, showing how strongly the evaluation unit affects the reported performance.**

***Keywords*—graph neural networks; GraphSAGE; anomaly detection; weather forecasting; extreme events; feature propagation.**

***Resumo*—Chuvas extremas causam alagamentos recorrentes e perdas materiais na Região Metropolitana de São Paulo. Este artigo modela 35 estações meteorológicas da região como um grafo ponderado pela proximidade geográfica, reconstrói com *Feature Propagation* as séries das estações sem histórico utilizável e treina uma rede GraphSAGE para prever pluviosidade e temperatura 60 minutos à frente (treino em 2016–2022, validação em 2023 e teste em 2024). Diferentemente das abordagens que tratam essas tarefas de forma independente, a arquitetura proposta integra reconstrução espacial, previsão meteorológica e detecção multivariada de anomalias em um único pipeline baseado em grafos para redes meteorológicas urbanas. A temperatura é prevista com alta fidelidade (correlação de 0,97 e RMSE inferior ao da persistência), ganho para o qual os experimentos de ablação indicam contribuição da estrutura do grafo. Os modelos avaliados não apresentaram desempenho satisfatório na previsão da magnitude da chuva forte, nas condições deste experimento, limitação evidenciada pela análise dos incrementos nas janelas de chuva forte; um STGCN com janela de duas horas reduz o RMSE de temperatura em mais 38%, embora os picos de chuva forte sigam subestimados. Para a precipitação, o sistema é avaliado como detector retrospectivo, por um escore multivariado de Mahalanobis sobre os erros de previsão. Na avaliação retrospectiva agregada por dia e pela rede, o detector alcançou revocação de 100% nos 80 dias positivos de 2024, mas com precisão de 21,9% e especificidade de 0%, sinalizando todos os dias do período. Na avaliação por estação e janela de 60 minutos, a revocação foi de aproximadamente 48%, com precisão de 20%, evidenciando a influência da unidade de avaliação sobre o desempenho reportado.**

***Palavras-chave*—redes neurais em grafos; GraphSAGE; detecção de anomalias; previsão meteorológica; eventos extremos; propagação de características.**

I. Introdução

São Paulo está entre as metrópoles mais expostas a chuvas intensas. Na capital, dias com precipitação acima de 50 mm, praticamente inexistentes nos registros até a década de 1950, tornaram-se ocorrência anual, e o número de dias de chuva extrema mais que quadruplicou em sete décadas, acompanhado de alagamentos, deslizamentos e perdas humanas e materiais [1]. O quadro acompanha tendência mais ampla documentada pelo IPCC: extremos de precipitação vêm se intensificando na maior parte das regiões habitadas [2]. Na madrugada de 13 de janeiro de 2024, um único temporal despejou quase 180 mm sobre

a zona sul da cidade em poucas horas, volume próximo ao esperado para o mês inteiro. Episódios como esse mostram o valor de antecipar condições extremas a partir do monitoramento contínuo da rede urbana de estações.

Antecipar, nesse cenário, é um problema técnico com três dificuldades combinadas. As observações formam séries temporais multivariadas (pluviosidade, temperatura, umidade relativa e velocidade do vento) com forte dependência espacial: o estado de uma estação carrega informação sobre o de suas vizinhas. A rede é também institucionalmente heterogênea, reunindo estações do Centro de Gerenciamento de Emergências Climáticas (CGE), do IAG-USP e do INMET, parte delas sem séries históricas disponíveis ao projeto; esses *nós cegos*, se usados sem tratamento, apenas injetam ruído em qualquer modelo relacional. Por fim, um alerta só tem utilidade prática se preceder o evento, o que obriga a separar o que é computável a partir da previsão do que só existe depois que a observação chega.

Enfrentamos essas dificuldades modelando a rede de estações como um grafo e aprendendo sua dinâmica com redes neurais em grafos (GNNs). As contribuições do trabalho são três. A primeira é a modelagem da rede metropolitana como um grafo ponderado pelo inverso da distância de Haversine, cuja difusão adota normalização estocástica por linha ($D^{-1}A$); é decisão metodológica, não alegação de superioridade experimental: garante que a reconstrução dos nós cegos seja combinação convexa dos vizinhos, dentro do intervalo físico medido. A segunda é a incorporação das estações sem dados históricos por *Feature Propagation*, interpolação harmônica iterativa que integra a reconstrução ao mesmo grafo sobre o qual a GNN opera, sem contaminar o treinamento; a Seção IV-B mostra que isso não se traduz em ganho de acurácia sobre uma média espacial simples. A terceira é um mecanismo duplo de detecção de anomalias, que une um limiar climatológico sazonal aplicado sobre a *previsão* a um escore multivariado de Mahalanobis calculado sobre o erro de previsão, mecanismo avaliado em um ano completo de dados reais e ilustrado no estudo de caso do temporal de 13 de janeiro de 2024.

A investigação que estrutura o artigo é, portanto, em que medida uma representação em grafo de uma rede meteorológica urbana pode apoiar a previsão de temperatura, a reconstrução espacial de estações sem histórico e a detecção de eventos de chuva forte.

II. Revisão da Literatura

A. Fundamentos

Uma anomalia climática é um desvio significativo entre o estado observado (ou previsto) e a climatologia de referência do local e da época; eventos extremos ocupam as caudas dessa distribuição e vêm se tornando mais frequentes e intensos [2]. A previsão numérica (NWP) [3] tem custo alto e diz pouco sobre o curtíssimo prazo na escala de bairro (*nowcasting*), espaço em que o aprendizado profundo avança, do *nowcasting* por radar [4] a modelos globais como o GraphCast [5] e o Pangu-Weather [6], como registram revisões recentes [7].

As redes neurais em grafos (GNNs) seguem o arcabouço de *message passing*: a cada camada, cada nó agrega mensagens dos vizinhos, e k camadas capturam dependências de até k saltos [8]–[10]. Em uma rede de estações, a homofilia (nós conectados com valores semelhantes) tem leitura física: estações próximas estão sujeitas às mesmas condições de mesoescala. O GraphSAGE [11] aprende funções de agregação sobre a vizinhança, em vez de uma representação fixa por nó; esse caráter indutivo, que generaliza para nós ausentes do treinamento e aceita ponderações pela geometria da rede, motivou sua escolha.

B. Trabalhos Relacionados

A detecção de anomalias em séries temporais com aprendizado profundo é campo maduro [12]; este trabalho pertence à família *baseada em previsão*, que sinaliza anomalia quando previsto e observado divergem. GNNs com mecanismos temporais estabeleceram referências na previsão de tráfego, com o DCRNN [13] e o STGCN [14], e na previsão global sobre reanálise [5], [15], mas sobre malhas densas e homogêneas; o cenário aqui é uma rede urbana esparsa, heterogênea e sujeita a falhas de medição.

Mais próximos deste cenário, trabalhos recentes aplicam GNNs a estações de superfície para previsão local [16] e de temperatura urbana em alta resolução [17]. Estimar variáveis em locais sem sensor é tratado como *kriging* indutivo em grafos [18], e o *Feature Propagation* reconstrói *features* ausentes minimizando a energia de Dirichlet [19]. Já a precipitação convectiva em dezenas de minutos depende da estrutura e do deslocamento das células de chuva, ausentes das variáveis de superfície [4], [7], o que justifica avaliar separadamente temperatura, magnitude da precipitação e detecção. Esses avanços raramente aparecem integrados em uma única arquitetura para redes urbanas de estações; é nessa lacuna que este trabalho se posiciona, combinando previsão por GNN, reconstrução de nós cegos por *Feature Propagation* e duas regras de detecção sobre uma rede real de 35 estações de três instituições.

III. Metodologia

A arquitetura encadeia quatro etapas: integração das séries das instituições participantes em uma grade temporal unificada; representação das estações como grafo ponderado pela proximidade geográfica; reconstrução das séries ausentes por *Feature Propagation*; e previsão de pluviosidade e temperatura por dois

modelos GraphSAGE independentes. As previsões alimentam dois mecanismos complementares de detecção: um limiar climatológico sazonal sobre a previsão, portanto antecipado, e um escore multivariado de Mahalanobis sobre o erro, disponível apenas quando a observação chega.

A. Conjuntos de Dados

A principal fonte de dados é a rede do Centro de Gerenciamento de Emergências Climáticas da Prefeitura de São Paulo (CGE): 32 estações telemétricas com leituras a cada 10 minutos de pluviosidade acumulada (mm), temperatura (°C), umidade relativa (%) e velocidade do vento (m/s), de 2016 a 2024 — a única fonte com séries históricas disponíveis ao treinamento. Integram ainda a topologia do grafo a estação do Instituto de Astronomia, Geofísica e Ciências Atmosféricas da USP (IAG-USP, nó 33) e as duas do Instituto Nacional de Meteorologia (INMET) na capital, Interlagos (nó 34) e Mirante de Santana (nó 35), que entram apenas com a posição geográfica: a série do IAG-USP só foi disponibilizada ao projeto na fase final, e as do INMET são totais horários em UTC, com semântica distinta da do CGE. São os três nós cegos tratados pelo *Feature Propagation*. O grafo resultante possui $N = 35$ nós e 85 arestas não direcionadas.

As leituras são registradas a cada 10 minutos e foram alinhadas em uma grade temporal unificada de 10 minutos, totalizando 52.704 instantes em 2024. Nessa grade, e apenas nos 32 nós observados, a fração de células sem leitura em 2024 é de $3{,}75\,\%$ na pluviosidade, $5{,}74\,\%$ na temperatura, $5{,}57\,\%$ na umidade relativa e $32{,}37\,\%$ na velocidade do vento, de longe a variável mais lacunar; no período de treino as lacunas concentram-se nos primeiros anos, com as séries bem mais completas a partir de 2022.

A Tabela I caracteriza as séries utilizadas em cada ano, considerando a disponibilidade das observações e a distribuição das variáveis meteorológicas. Essa descrição permite examinar diferenças entre os períodos de treinamento, validação e teste e identificar possíveis efeitos da cobertura dos registros. Os indicadores usam a grade de 10 minutos dos 32 nós observados, antes de qualquer imputação, com o mesmo critério em todos os anos. Como o pluviômetro registra um contador acumulado, reiniciado periodicamente, a precipitação não soma os valores registrados: o incremento de 10 minutos é a diferença entre leituras consecutivas ou, após um reinício, a própria leitura. O total anual soma esses incrementos nas células observadas, sem preencher lacunas, e o valor da rede é a mediana entre as estações com cobertura de pluviosidade de ao menos $90\,\%$, para que estações com longas falhas não reduzam artificialmente o total.

O preenchimento é feito em cascata: interpolação temporal bidirecional, propagação do último valor válido e, só onde uma variável está integralmente ausente em uma estação, imputação por 0 na pluviosidade e pela média global nas demais; o arquivo bruto do CGE não distingue registro válido sem chuva de falha, e a sensibilidade a essa escolha não foi analisada. A interpolação atua antes da formação dos pares $t \to t + 60$ min e dentro de cada ano, sem atravessar as fronteiras entre treino, validação e teste; ainda assim, uma célula faltante em t pode ser preenchida por uma leitura posterior a t, o que um cenário estritamente operacional não admitiria (Seção V).

A divisão dos dados em treinamento, validação e teste segue a ordem cronológica: 2016 a 2022 para treinamento, 2023 para validação e todo o ano de 2024 para teste. Os limiares climatológicos τ e as covariâncias Σ_i são estimados sobre o histórico de 2016 a 2023. Entretanto, a imputação bidirecional pode utilizar observações posteriores à origem da previsão, de modo que os resultados de previsão também caracterizam uma avaliação retrospectiva e não demonstram desempenho em operação causal.

Para contextualizar climaticamente os três períodos, a Tabela I inclui o Índice Oceânico do Niño (ONI) do NOAA/CPC, na versão baseada no ERSSTv5 [20]. As fases seguem o critério do CPC (anomalia trimestral móvel $\geq +0{,}5$ ou $\leq -0{,}5\,°\mathrm{C}$ por ao menos cinco trimestres consecutivos) e, como mudam ao longo do ano, são registradas em sequência, e não como fase única por ano. O treino abrange as duas fases; a validação de 2023 marca a transição da La Niña para um El Niño que atinge ONI de $1{,}99$; o teste de 2024 começa sob esse El Niño, em declínio, e termina neutro.

B. Representação em Grafo

A rede é modelada como um grafo não direcionado $G = (V, E)$, com uma estação por nó. A topologia foi traçada manualmente, ligando cada estação às dos distritos vizinhos para reproduzir a contiguidade da malha urbana, sem raio máximo nem k vizinhos: o grafo é conexo, com grau entre 2 e 9 (média 4,9) e arestas de 1,9 a 28,6 km (mediana 7,8 km). A construção incorpora conhecimento local, mas não é reprodutível por regra automática. O peso da aresta é o inverso da distância de Haversine [21], com raio médio da Terra $R = 6.371$ km:

$$w_{ij} = \frac{1}{\max\big(d(i,j),\ 0{,}1\big)} \tag{1}$$

em que o limite de $0{,}1$ km é só uma salvaguarda numérica (a menor aresta tem $1{,}9$ km). Os pesos são normalizados por nó de destino, utilizando $D^{-1}A$:

$$\tilde{w}_{ij} = \frac{w_{ij}}{\sum\limits_{k \in \mathcal{N}(i)} w_{ik}} \tag{2}$$

Tabela I
CARACTERIZAÇÃO ANUAL DAS SÉRIES DOS 32 NÓS OBSERVADOS E CONTEXTO CLIMÁTICO DO ENSO. EST. = ESTAÇÕES COM AO MENOS UMA LEITURA (PLUVIOSIDADE/TEMPERATURA); LAC. = CÉLULAS SEM LEITURA NA GRADE DE 10 MIN; $\bar{T}$ = MÉDIA DAS MÉDIAS ANUAIS POR ESTAÇÃO; P = MEDIANA, ENTRE AS ESTAÇÕES COM COBERTURA $\geq 90\,\%$, DO TOTAL ANUAL RECONSTRUÍDO PELOS INCREMENTOS; CF = DIAS COM CHUVA FORTE NA REDE, PELA DEFINIÇÃO DA SEÇÃO IV-C. ONI = ÍNDICE OCEÂNICO DO NIÑO (NOAA/CPC, ERSSTV5 [20]), MÍNIMO E MÁXIMO DAS MÉDIAS TRIMESTRAIS MÓVEIS DO ANO; EN = EL NIÑO, LN = LA NIÑA, N = NEUTRO, COM OS TRIMESTRES DE INÍCIO OU FIM DE CADA EPISÓDIO.

Ano	Uso	Est.	Lac. PLU (%)	Lac. Temp (%)	$\bar{T}$ (°C)	P (mm)	CF (dias)	ONI mín/máx	Fases ENSO
2016	treino	31/30	3,24	8,12	19,93	1.354	99	−0,51 / +2,50	EN (DJF–AMJ) → N
2017	treino	30/30	6,40	9,46	20,02	1.508	99	−0,76 / +0,35	N → LN (a partir de OND)
2018	treino	31/31	3,50	7,93	20,05	1.101	91	−0,71 / +1,05	LN (até FMA) → N → EN (a partir de ASO)
2019	treino	31/31	3,76	4,90	20,49	1.599	115	+0,20 / +0,99	EN (até MJJ) → N → EN (a partir de SON)
2020	treino	31/31	3,84	4,90	19,89	1.413	84	−1,11 / +0,71	EN (até FMA) → N → LN (a partir de ASO)
2021	treino	32/32	2,57	4,43	19,49	1.233	89	−0,99 / −0,31	LN (até MAM) → N → LN (a partir de ASO)
2022	treino	32/32	0,62	0,94	19,40	1.467	103	−0,89 / −0,68	LN no ano todo
2023	validação	32/32	0,28	0,97	20,45	1.561	100	−0,55 / +1,99	LN (DJF) → N → EN (a partir de MJJ)
2024	teste	32/32	3,75	5,74	20,88	1.344	80	−0,43 / +1,84	EN (até MAM) → N

de modo que os pesos incidentes em cada nó somem 1. Para o GraphSAGE a escolha é indiferente, pois sua agregação (Equação (3)) divide pela soma dos pesos; no *Feature Propagation*, cuja difusão $X \leftarrow \tilde{A}X$ não divide, ela é decisiva. A normalização por linha garante que os pesos de cada atualização somem 1, produzindo uma combinação convexa dos valores vizinhos. A normalização simétrica e a normalização min-max não asseguram essa propriedade.

C. Feature Propagation nos Nós Cegos

Os três nós cegos (33, 34 e 35) participam da propagação de mensagens, mas suas *features* são desconhecidas. Para estimá-las, adotamos o *Feature Propagation* [19], que supõe homofilia de *features*, hipótese razoável para estações próximas, e minimiza a energia de Dirichlet, produzindo uma interpolação harmônica para os nós desconhecidos. A cada iteração, faz-se $X^{(r)} \leftarrow \tilde{A}\,X^{(r-1)}$ e restauram-se os valores dos nós com dados reais, $X^{(r)}_{\mathcal{K}} \leftarrow X^{(0)}_{\mathcal{K}}$; utilizamos $R = 40$ iterações, suficientes para a convergência. A reconstrução é espacial e sem parâmetros treináveis, resolvida em cada instante com os valores medidos pelos vizinhos naquele instante, e antecede o GraphSAGE; a validação da Seção IV-B isola, assim, sua qualidade.

D. Modelo GraphSAGE

Dado o tensor de *features* $X_t \in \mathbb{R}^{N\times F}$, o modelo aprende o resíduo $\Delta = X_{t+h} - X_t$ e prevê $\hat{X}_{t+h} = X_t + \hat{\Delta}$, com $h = 6$ passos de 10 minutos (60 minutos). A entrada é apenas o estado instantâneo X_t, sem mecanismo temporal: o modelo aprende uma relação *espacial* entre o estado atual e o valor 60 minutos à frente, e o custo dessa escolha é medido pelo STGCN da Seção III-E. Adotamos o GraphSAGE [11] com agregação média ponderada pelos pesos das arestas (*WeightedSAGEConv*):

$$h'_i = W_{\text{self}}\,x_i + W_{\text{neigh}}\,\frac{\sum_{j\in\mathcal{N}(i)} \tilde{w}_{ij}\,x_j}{\sum_{j\in\mathcal{N}(i)} \tilde{w}_{ij}} \tag{3}$$

em que W_{self} e W_{neigh} são aprendíveis e $\tilde{w}_{ij}$ vem da Equação (2). A rede tem duas dessas camadas ($4 \to 64 \to 1$) separadas por ReLU, com custo $O(|E|\cdot d)$ por camada, o que viabiliza a operação em tempo real.

Treinamos dois modelos independentes, para pluviosidade (PLU) e temperatura (Temp), ambos com as quatro *features* de entrada. A perda é o erro quadrático médio sobre os nós com dados reais ($\mathcal{K}$), com os cegos mascarados; o otimizador é o Adam ($\eta = 0{,}001$), com até 300 épocas, parada antecipada (paciência 25) e redução da taxa de aprendizado monitorando a perda de validação de 2023. O modelo final é o de menor erro de validação, e 2024 nunca entra no ajuste.

E. Modelo Espaço-Temporal de Referência (STGCN)

Para medir o que a ausência de memória temporal custa, treinamos um STGCN [14] no mesmo protocolo e com as mesmas três sementes, com entrada nas últimas $W = 12$ observações (duas horas) e o mesmo alvo. Ele empilha dois blocos com convolução temporal com portões GLU (núcleo 3), convolução espacial com a agregação da Equação (3) e os mesmos pesos $D^{-1}A$, e nova convolução temporal. A comparação não é uma ablação perfeitamente controlada, pois os portões GLU também acrescentam capacidade, mas a principal diferença para o GraphSAGE é o acesso à evolução recente da rede.

F. Detecção de Anomalias

A detecção combina duas regras. A Regra 1 opera sobre a previsão e é computável em t, com 60 minutos de antecedência. A Regra 2 opera sobre o erro de previsão, exige x_{t+h} e só pode ser calculada quando a observação chega: é detecção

retrospectiva, não alerta antecipado. As métricas principais da Seção IV-C referem-se à Regra 2, e a Regra 1 é avaliada ao final daquela seção. Ambas usam uma previsão completa $\hat{x}_{t+h} \in \mathbb{R}^{N \times F}$: pluviosidade e temperatura vêm dos modelos GraphSAGE, e umidade e vento, da persistência.

Regra 1: limiar climatológico sobre a previsão: Para cada mês m, estação i e variável k, define-se o limiar $\tau_{m,i,k}$ como o percentil 95 das observações históricas (2016 a 2023) daquele mês; o cálculo mensal captura a sazonalidade, pois um acumulado de chuva comum em janeiro pode ser excepcional em agosto. Um alerta bruto é disparado no instante t quando a *previsão* ultrapassa o limiar do mês corrente, $\hat{x}_{t+h,i,k} > \tau_{m(t),i,k}$. Por agir sobre a previsão, e não sobre a observação, a regra sinaliza a condição anômala antes de sua confirmação pelo sensor. Para suprimir falsos positivos causados por *spikes* isolados, o alerta só é confirmado após $n_c = 3$ ativações consecutivas (janela anti-ruído, distinta da janela de entrada $W = 12$ do STGCN).

Regra 2: anomaly score multivariado de Mahalanobis: A Regra 1 avalia cada variável isoladamente. A Regra 2 captura combinações incomuns entre variáveis por meio da distância de Mahalanobis [22] do erro de previsão. Para cada estação i, estima-se sobre o histórico de 2016 a 2023 a matriz de covariância $\Sigma_i \in \mathbb{R}^{F \times F}$ entre as F variáveis. O *anomaly score* no instante t é:

$$AS_{t,i} = \sqrt{e_{t,i}^{\top} \Sigma_i^{+} e_{t,i}}\,, \qquad e_{t,i} = x_{t+h,i} - \hat{x}_{t+h,i} \tag{4}$$

onde Σ_i^{+} é a pseudo-inversa de Moore–Penrose de Σ_i, empregada porque a covariância pode ser singular ou mal-condicionada quando há variáveis fortemente correlacionadas. Embora o escore esteja indexado pela origem da previsão t, seu cálculo exige a observação em $t + h$ e, portanto, somente fica disponível nesse instante. Ele caracteriza uma detecção retrospectiva em relação à previsão emitida em t. Ao ponderar o erro pela covariância histórica, um desvio em uma variável estável pesa mais do que o mesmo desvio em uma variável volátil, e desvios conjuntos que violam a correlação usual elevam o escore mesmo quando nenhuma variável isolada ultrapassa seu limiar; o valor contínuo do escore ranqueia os eventos detectados.

Os limiares p99 e p99,9 que convertem o escore em decisão na Seção IV-C são percentis da distribuição empírica de $AS_{t,i}$ no próprio ano de teste, agrupando as 32 estações observadas e todos os instantes de 2024. Diferentemente de τ e Σ_i, estimados sobre 2016 a 2023, esses limiares não são calibrados antes do teste: fixam a fração de pares estação–instante sinalizados (1 % e 0,1 %) e servem à avaliação retrospectiva, não a uma operação prospectiva, que exigiria estimá-los sobre o histórico. Como a decisão diária toma o máximo do escore sobre 32 estações e 144 instantes, um percentil 99 por estação-instante é ultrapassado em todos os dias, o que explica a especificidade baixa reportada adiante.

G. Configuração Experimental

As métricas reportadas são o erro absoluto médio (MAE) e a raiz do erro quadrático médio (RMSE), calculadas exclusivamente sobre os 32 nós com dados observados. Os experimentos foram executados em Python com *PyTorch Geometric*, em uma máquina com processador AMD Ryzen 7 5700X3D, 24 GB de memória RAM e GPU NVIDIA RTX 3070 de 8 GB.

Dois *baselines* de previsão são considerados: a média histórica (previsão constante igual à média da série de cada estação) e a persistência ($\hat{x}_{t+h} = x_t$), referência padrão em *nowcasting* de curtíssimo prazo.

Todos os resultados vêm de uma única divisão temporal (treino 2016–2022, validação 2023, teste 2024). Uma segunda divisão, com treino em 2016–2021, validação em 2022 e teste em 2023, exigiria recalcular com dados anteriores a 2023 todos os componentes do pipeline, incluindo imputação, limiares e covariâncias, e não foi realizada neste trabalho; a limitação é discutida na Seção V.

IV. Resultados e Discussão

A. Previsão e Ablação

A Tabela II avalia, no teste de 2024, esses dois *baselines* e quatro configurações que isolam cada componente: um MLP sem grafo, que só vê as *features* do próprio nó; o GraphSAGE sem pesos, com média simples dos vizinhos; o GraphSAGE ponderado, com média ponderada pelo inverso da distância; e o STGCN, que acrescenta a janela de duas horas à mesma agregação espacial. As configurações são avaliadas no mesmo protocolo temporal, com três sementes cada. A comparação com o STGCN envolve tanto a inclusão da janela temporal quanto diferenças de capacidade arquitetural, conforme descrito na Seção III-E.

O desempenho é homogêneo entre as 32 estações: o RMSE por estação varia de 0,75 a 1,55 °C na temperatura (mediana 1,18) e de 1,25 a 3,30 mm na pluviosidade (mediana 2,47), sem nenhuma estação destoando a ponto de dominar a média agregada. Na temperatura, a correlação de Pearson entre previsto e observado, agrupando os 32 nós e todos os instantes de 2024, é de 0,97.

A tabela mostra, sem atenuação, que em MAE a persistência supera *todas* as configurações neurais instantâneas, na pluviosidade (0,286 contra 0,388 a 0,393) e na temperatura (0,811 contra 0,828 a 0,838); só o STGCN a supera no RMSE das duas variáveis. Repetir o último valor é um competidor forte nesta escala. Ela não substitui o modelo — não estima nada nos

Tabela II
ERRO DE PREVISÃO A 60 MINUTOS EM 2024, AGREGADO NOS 32 NÓS OBSERVADOS. CONFIGURAÇÕES NEURAIS EM MÉDIA ± DESVIO POPULACIONAL DE TRÊS SEMENTES; O STGCN É O ÚNICO MODELO COM JANELA TEMPORAL. PLU EM MM; TEMP EM °C. NA PLUVIOSIDADE, O ERRO SOBRE O ACUMULADO COINCIDE COM O ERRO SOBRE O INCREMENTO EM 60 MIN; A ANÁLISE POR INTENSIDADE VEM ADIANTE NESTA SEÇÃO.

	Pluviosidade		**Temperatura**	
Modelo	MAE	RMSE	MAE	RMSE
Média histórica	2,917	6,767	3,634	4,631
Persistência	**0,286**	2,484	0,811	1,273
MLP sem grafo	0,388 ±0,005	2,510 ±0,003	0,838 ±0,001	1,248 ±0,001
GraphSAGE sem pesos	0,391 ±0,003	2,501 ±0,002	0,828 ±0,004	1,213 ±0,003
GraphSAGE ponderado	0,393 ±0,004	2,504 ±0,002	0,828 ±0,005	1,210 ±0,002
STGCN (janela 2 h)	0,301 ±0,010	**2,407** ±0,002	**0,466** ±0,006	**0,751** ±0,006

nós cegos, que por definição não têm último valor a repetir —, mas seu erro alimenta a detecção multivariada com desempenho equivalente (Seção IV-C).

A Tabela II apresenta os erros de previsão do acumulado registrado pelo pluviômetro. Para avaliar a chuva ocorrida em 60 minutos, o incremento observado foi obtido pela diferença entre os acumulados registrados em $t + h$ e em t, enquanto o incremento previsto é a própria saída do modelo, que estima essa diferença (o resíduo $\hat{\Delta}$); para a persistência, o incremento previsto é nulo. Nas janelas que atravessam o reinício diário do contador (1,47 % das janelas de 2024), a diferença observada fica negativa: no treinamento ela foi truncada em zero, e na avaliação foi mantida, de modo que essas janelas entram no regime seco. As previsões negativas de incremento foram truncadas em zero. A análise por intensidade permite examinar o desempenho nas janelas de chuva forte, que pode ficar pouco evidente nas métricas agregadas. Nessas janelas, os modelos avaliados não apresentaram desempenho satisfatório na previsão da magnitude da chuva forte a 60 minutos, nas condições deste experimento: o modelo, como a persistência, converge para perto de zero e não antecipa os picos. Os resultados delimitam o desempenho das configurações testadas, mas não demonstram impossibilidade geral de previsão com estações de superfície. O resultado sugere uma limitação informacional, e não apenas de ajuste: o estado instantâneo da rede não carrega a informação (radar, umidade em altitude) que determina o volume de chuva na hora seguinte.

Estratificar o incremento por regime revela uma nuance. Nas janelas *secas* (incremento $< 0{,}2$ mm, 93 % dos casos), prever zero é ótimo e a persistência supera o GraphSAGE (0,15 contra 0,30 de MAE). Na chuva *moderada* (0,2–10 mm), o GraphSAGE de fato ajuda (1,10 contra 1,40). Mas na chuva *forte* (≥ 10 mm; o limite fechado torna as três faixas exaustivas, enquanto a definição de evento da Seção IV-C usa > 10 mm, e os dois critérios só diferem para incrementos iguais a 10 mm), o regime que importa, ambos falham por quase todo o volume (17,5 e 18,3 mm de MAE sobre uma chuva média de 18,3 mm): preveem perto de zero enquanto chove forte. A habilidade que existe está no regime que menos precisa dela — resultado que desloca o valor do sistema, para a precipitação, da previsão de magnitude para a detecção (Seção IV-C).

Tabela III
VALIDAÇÃO DO NÓ CEGO 33 CONTRA AS MEDIÇÕES REAIS DO IAG-USP (AGREGADOS DIÁRIOS, 366 DIAS DE 2024). FP = *Feature Propagation*; MV = MÉDIA DOS VIZINHOS.

Variável	**Método**	MAE	RMSE	r
Precipitação (mm/dia)	FP	2,10	6,69	0,81
	MV	2,14	6,74	0,80
Temperatura (°C)	FP	2,47	4,17	0,73
	MV	2,46	4,16	0,73
Umidade relativa (%)	FP	15,57	17,19	0,87
	MV	14,96	16,56	0,88

B. Estimativas nos Nós Cegos: Validação com Dados Reais

Na fase final do trabalho, as séries de 2024 do IAG-USP foram disponibilizadas, permitindo avaliar diretamente, pela primeira vez, a reconstrução espacial produzida para um nó cego pelo *Feature Propagation*, isolada do GraphSAGE. A comparação usa agregados diários e contrasta o *Feature Propagation* com a média simples dos vizinhos (uma iteração de difusão, sem restauração de âncoras), como resume a Tabela III.

Com o nó em sua localização real, no Parque Estadual das Fontes do Ipiranga, as estimativas ficam dentro do intervalo físico medido e acompanham a variação diária observada. Na temperatura, o *Feature Propagation* reproduz a média anual com desvio de cerca de 2 °C (20,84 contra 22,89 °C), com MAE diário de 2,47 °C e correlação de 0,73. Na precipitação, o total anual é subestimado em torno de 13 % (1.425 contra 1.641 mm), com MAE de 2,10 mm/dia e correlação de 0,81, mas eventos convectivos concentrados podem ser superestimados, como o de 13/01 discutido no estudo de caso. Na umidade relativa os dois métodos superestimam as medições (82 contra 66 % na média anual), embora com correlação diária de 0,87: as estações vizinhas, mais urbanas, são sistematicamente mais úmidas que a do IAG, em área de mata. A validação sustenta a plausibilidade física da reconstrução e uma aderência diária razoável, com vieses de nível na temperatura e na umidade.

Os dois métodos são aqui praticamente equivalentes: quando o nó cego está bem cercado por âncoras confiáveis, a difusão harmônica e a média simples convergem para a mesma estimativa. Com $D^{-1}A$, os três nós cegos permanecem no intervalo físico plausível.

Avaliamos também o método por mascaramento artificial: cada uma das 32 estações observadas foi escondida por vez e reconstruída a partir dos vizinhos (valores instantâneos de 2024, amostragem horária). O *Feature Propagation*, a média dos vizinhos e a ponderação pelo inverso da distância (IDW) são indistinguíveis (MAE de temperatura 1,12, 1,13 e 1,10 °C), e interpoladores clássicos não os superam: a krigagem ordinária degrada na precipitação (MAE 1,48 contra ≈ 0,86 mm), e a interpolação linear, indefinida fora do fecho convexo da rede, exclui sete estações. Esses experimentos não demonstram superioridade do *Feature Propagation* sobre uma média espacial simples; sua vantagem é a integração ao grafo da GNN e a operação com várias camadas de vizinhança, útil quando o nó cego não tem âncoras imediatas.

C. Detecção de Eventos de Chuva Forte

Estabelecida a limitação da previsão de magnitude, avaliamos a capacidade de *detecção*. Definimos como evento um dia em que ao menos uma estação registrou chuva superior a 10 mm em 60 minutos (o incremento real), o que ocorreu em 80 dos 366 dias de 2024; o dia é sinalizado quando o *anomaly score* de alguma estação ultrapassa o limiar percentil definido na Seção III-F.

Após a revisão da leitura das datas dos registros, cuja conversão anterior invertia dia e mês nos dias 1 a 12 de cada mês e criava saltos artificiais no acumulado de chuva na emenda entre dias, foram identificados 80 dias civis com ao menos uma janela de chuva superior a 10 mm em 60 minutos nas 32 estações observadas. Essa contagem fundamenta a distribuição apresentada na Tabela IV e as métricas da Tabela V; todos os resultados deste artigo foram recalculados com a leitura corrigida. A contagem não corresponde ao número de episódios independentes, pois um mesmo episódio pode abranger várias estações e janelas consecutivas. A distribuição temporal e espacial dos eventos é apresentada na Tabela IV, que distingue o dia positivo na rede, a ocorrência por estação e a janela positiva. As janelas de 60 minutos deslizam a cada 10 minutos e são, portanto, sobrepostas; a tabela reporta também os episódios, com as janelas positivas consecutivas de uma estação fundidas, e janelas não são tratadas como eventos meteorológicos independentes.

A Tabela V revela o custo da agregação diária: no percentil 99, o escore diário máximo da rede excede o limiar em todos os dias (especificidade 0 %), de modo que a revocação de 100 % na avaliação diária agregada da rede vem acompanhada de indiscriminação; só no percentil 99,9 o detector discrimina (especificidade 52 %, F1 0,49). Um *bootstrap* de 2000 reamostragens situa a precisão do p99 em 21,8 % (IC 95% [17,8; 26,2]). A precisão no p99 coincide com a proporção de dias positivos no conjunto de teste (80/366 ≈ 21,9 %), isto é, com a precisão

Tabela IV
DISTRIBUIÇÃO DOS 80 DIAS POSITIVOS DE CHUVA FORTE (> 10 MM/60 MIN) EM 2024. JANELAS DE 60 MIN DESLIZANTES A CADA 10 MIN (SOBREPOSTAS), DATADAS PELO INSTANTE-ALVO; EPISÓDIO = JANELAS POSITIVAS CONSECUTIVAS DA MESMA ESTAÇÃO FUNDIDAS.

Mês	J	F	M	A	M	J	J	A	S	O	N	D
Dias pos.	18	12	13	6	2	0	0	1	1	6	7	14

Estações com chuva forte por dia positivo: mediana 7; p90 20; máx. 32

	00–06h	06–12h	12–18h	18–24h
Janelas pos.	1.063	101	577	2.980
Episódios	140	21	136	493

mm/60 min	10–20	20–30	30–50	> 50
Janelas pos.	3.275	964	426	56

Intensidade nas janelas positivas: mediana 15,6; p90 30,2; p99 51,5; máx. 77,4 mm
Total: 4.721 janelas positivas em 790 episódios

Tabela V
DETECÇÃO RETROSPECTIVA DE CHUVA FORTE EM 2024 (CHUVA REAL > 10 MM/60 MIN) NAS DUAS UNIDADES DE AVALIAÇÃO. MAHAL. + PERS. = MAHALANOBIS COM PERSISTÊNCIA, MESMO ESCORE CALCULADO SOBRE O ERRO DE PERSISTÊNCIA, SEM GRAPHSAGE. NA UNIDADE ESTAÇÃO–JANELA, MÉTRICAS MÉDIAS ENTRE AS 32 ESTAÇÕES, TOLERÂNCIA DE ±30 MIN. REV. = REVOCAÇÃO; ESP. = ESPECIFICIDADE; POS. = OCORRÊNCIAS POSITIVAS AVALIADAS; – = NÃO CALCULADO NESSA UNIDADE.

Unidade	**Detector**	**Limiar**	**Rev.**	**Prec.**	**F1**	**Esp.**	**Pos.**
Dia × rede	GraphSAGE	p99	100 %	21,9 %	0,36	0 %	80 de 366 dias
		p99,9	87,5 %	33,8 %	0,49	52 %	
	Mahal. + pers.	p99	100 %	21,9 %	0,36	0 %	
		p99,9	87,5 %	34,0 %	0,49	52 %	
Estação × janela	GraphSAGE	p99	48 %	20 %	0,26	–	4.721 janelas

obtida ao classificar todos os dias como positivos, indicando que o recall elevado, isoladamente, não caracteriza capacidade satisfatória de discriminação. Mais revelador, a referência *Mahalanobis com persistência* — a mesma distância de Mahalanobis, mas sobre o erro de *persistência*, sem GraphSAGE — reproduz o modelo quase exatamente (p99: 100/21,9 %; p99,9: 87,5/34,0 %). Parte dessa coincidência é mecânica: duas das quatro dimensões do erro (umidade e vento) são estimadas por persistência em ambos os detectores, de modo que só pluviosidade e temperatura estão em disputa — e nelas o erro do GraphSAGE não carrega mais informação de anomalia que o de repetir o último valor. Nas configurações avaliadas, a utilização do GraphSAGE não demonstrou ganho relevante na detecção em relação ao escore de Mahalanobis calculado sobre os erros de persistência. A contribuição da estrutura em grafo observada na previsão de temperatura deve, portanto, ser distinguida do desempenho do detector de chuva forte.

Uma avaliação mais severa confirma que a agregação diária infla o desempenho. Nessa unidade, a ocorrência é um par estação–janela de 60 minutos com incremento real > 10 mm. Ela conta como detectada se o escore da mesma estação ultrapassa o limiar a até ±30 min dela; uma ativação sem ocorrência

nesse intervalo é falsa. Como o escore já é retrospectivo, a tolerância só absorve o desalinhamento entre os picos do escore e da chuva, e não representa antecedência do alerta. Revocação, precisão e F1 são calculados por estação e promediados entre as 32 (média simples, não contagem global); as falsas ativações são divididas pelos dias do teste. Passos consecutivos não foram agrupados: cada passo de 10 minutos conta separadamente, e um episódio pesa proporcionalmente à sua duração. No percentil 99, a revocação média cai de 100 % para 48 % e a precisão para 20 % (F1 0,26), com cerca de 1,3 falsa ativação por estação a cada dia. A Tabela IV dimensiona a sobreposição: a fusão das janelas consecutivas reduz as 4.721 janelas positivas a 790 episódios, cerca de seis janelas por episódio, de modo que essas métricas não devem ser lidas como contagens de eventos meteorológicos independentes.

Cabe avaliar a Regra 1 isoladamente, já que, ao operar sobre a *previsão*, é o único componente genuinamente antecipado. Como antecipador de chuva forte por estação, seu desempenho é fraco: recupera 27 % dos episódios (12 % só pela componente de pluviosidade) e dispara cerca de 22 vezes por estação a cada dia, quase todas falsas, de modo que a antecedência mediana de 120 minutos é mais artefato da alta taxa de disparo que sinal operacional.

D. Discussão

A comparação que importa é com o MLP, que separa o efeito do grafo do mero aprendizado supervisionado. Na temperatura, a estrutura espacial apresenta contribuição consistente: o RMSE cai de 1,248 (MLP) para 1,213 (GraphSAGE sem pesos; 1,210 na variante ponderada), ganho de 0,035 contra desvio entre sementes de até 0,003, e o modelo supera a persistência no RMSE (1,21 contra 1,27), com vantagem concentrada nas transições bruscas. Na pluviosidade, as três configurações instantâneas são indistinguíveis: onde nenhuma apresentou desempenho satisfatório, o grafo nada acrescenta.

A janela temporal beneficia as duas variáveis em graus muito diferentes. O STGCN, único modelo com acesso às duas horas anteriores, é também o único a superar a persistência no RMSE da pluviosidade (2,407 contra 2,484, estável nas três sementes), embora seu MAE (0,301) continue acima do da persistência (0,286): a memória temporal reduz os erros grandes, mas a magnitude dos picos de chuva forte segue subestimada. Na temperatura, o STGCN alcança MAE de 0,466 e RMSE de 0,751 °C, reduções de cerca de 44 % e 38 % sobre o melhor modelo instantâneo. A tendência térmica das horas anteriores carrega informação que nenhuma arquitetura restrita a um único instante consegue usar; como o STGCN emprega a mesma agregação espacial e o mesmo protocolo, a comparação indica que parcela substancial desse ganho está associada à incorporação de memória temporal.

Um segundo resultado contraria uma expectativa do projeto: as versões com e sem pesos são indistinguíveis, e o ganho da ponderação pelo inverso da distância é nulo neste grafo, plausivelmente porque as arestas já ligam apenas estações vizinhas. O modelo usado no restante do artigo é o GraphSAGE ponderado.

O contexto climático também separa os períodos. O teste de 2024 começa sob um El Niño que, no treino, só tem paralelo no início de 2016, enquanto 2020–2022 foram dominados pela La Niña (Tabela I). Nas séries locais, 2024 foi o ano mais quente da série (20,88 °C, contra 19,40 a 20,49 °C no treino e 20,45 °C na validação) e o de menos dias com chuva forte (80, contra 84 a 115 no treino e 100 na validação), com precipitação anual (1.344 mm) dentro da faixa do treino (1.101 a 1.599 mm). O teste difere, portanto, do treino menos no volume de chuva que na frequência de eventos intensos e na temperatura. O paralelo com o ENSO não é direto: 2016, que também começou sob El Niño forte, não repetiu esse padrão (19,93 °C e 99 dias com chuva forte). Parte das diferenças entre anos também reflete a cobertura, com mais lacunas em 2016–2020 e em 2024 e uma ou duas estações ausentes até 2020. A caracterização do ENSO foi utilizada para contextualizar os períodos avaliados, enquanto as diferenças meteorológicas locais foram examinadas diretamente nas séries das estações. A associação entre fase climática e desempenho é exploratória e não permite atribuir causalidade ao ENSO: a fase contextualiza os períodos, mas não demonstra, sozinha, que os dados locais sejam semelhantes ou diferentes, nem explica os erros do modelo.

E. Estudo de Caso: o Temporal de 13 de Janeiro de 2024

Para ilustrar o sistema em operação, tomamos um dos eventos de maior magnitude de 2024: o temporal da madrugada de 13 de janeiro na zona sul. A Barragem Palheiros acumulou cerca de 176 mm entre as 20h de 12/01 e as 6h de 13/01, com 43,5 mm na hora mais chuvosa (0h–1h), e Capela do Socorro registrou 97,2 mm no dia 13. A Figura 1 mostra a detecção às 00h50, instante em que chega a observação necessária ao escore da previsão emitida às 23h50 do dia anterior: apenas 2 das 32 estações observadas apresentam *anomaly score* acima do percentil 99, Barragem Palheiros e Capela do Socorro – Subprefeitura, ambas sob chuva intensa naquela hora (30,0 e 16,2 mm). Ao longo da madrugada, o número de estações acima do p99 fica entre uma e duas, sempre entre as mais atingidas: a detecção é localizada, coerente com o caráter concentrado da chuva, e não uma exceção generalizada na rede. A figura revela também um limite da hipótese de homofilia: na estação IAG-USP o total do dia foi de apenas 16,5 mm, enquanto a interpolação harmônica, puxada pelos vizinhos sob chuva intensa, estimou 42,7 mm para aquele nó. Eventos convectivos concentrados são o regime que mais tensiona a

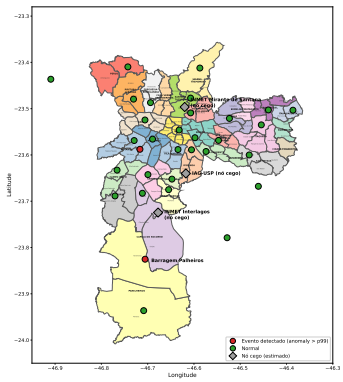


Figura 1. Detecção retrospectiva por anomalia no núcleo do temporal de 13/01/2024. O horário 00h50 é o instante $t+h$ em que a observação necessária ao escore fica disponível; a previsão correspondente foi emitida às 23h50 de 12/01. 2 das 32 estações observadas com *anomaly score* acima do percentil 99 (vermelho); losangos cinza são os nós cegos.

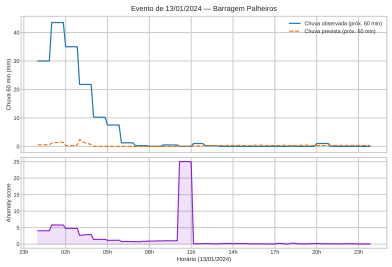


Figura 2. Evento de 13/01/2024 na estação Barragem Palheiros. O eixo horizontal é o instante-alvo $t+h$, fim da hora de chuva e momento em que o escore passa a estar disponível; cada previsão foi emitida 60 min antes. Acima: chuva observada na hora (azul) e prevista (laranja tracejado). Abaixo: *anomaly score* de Mahalanobis (Regra 2), calculado retrospectivamente sobre o erro de previsão.

suposição de que estações próximas compartilham o mesmo estado.

A Figura 2 torna explícito o limite discutido na Seção IV: enquanto a chuva real da hora atinge 43,5 mm no auge do temporal, a previsão permanece próxima de zero. É esse descompasso que a detecção aproveita. O *anomaly score* se eleva ao longo da madrugada, até 5,8 na Barragem, acima do p99 de 3,85, sinalizando o evento não por havê-lo previsto, mas por reconhecer que o estado multivariado se afasta do esperado. Os maiores escores do dia, porém, não vêm do temporal: surgem por volta das 10h, quando os pluviômetros reiniciam o contador, momento em que 31 das 32 estações ultrapassam o p99 e o escore da Barragem chega a 25. A Regra 2 responde a qualquer transição brusca, meteorológica ou instrumental, e aqui com mais intensidade à instrumental.

V. Conclusões

Avaliado em um ano completo de dados reais, o sistema integra em um único grafo de 35 nós a rede do CGE, o IAG-USP e o INMET, e comporta-se de modo distinto entre as variáveis. A temperatura é prevista com alta fidelidade (correlação de 0,97; RMSE de 1,21 °C contra 1,27 da persistência), com contribuição da estrutura do grafo, embora a ponderação pela distância empate com a média simples; o STGCN reduz os erros a 0,47 (MAE) e 0,75 °C (RMSE), sinal de que o próximo ganho está na memória temporal. Na precipitação, os modelos avaliados não apresentaram desempenho satisfatório na previsão da magnitude da chuva forte, nas condições deste experimento, e mesmo o STGCN subestima os picos.

Para a precipitação, o valor do sistema desloca-se da previsão para a detecção retrospectiva. Avaliado por dia e no nível agregado da rede, no limiar p99 o escore alcança 100 % de revocação, mas com precisão de 21,9 %, igual à proporção de dias positivos, e especificidade de 0 %: sinaliza todos os dias. No limiar p99,9 o detector passa a discriminar, ao custo de revocação: 87,5 % de revocação, 33,8 % de precisão e 52 % de especificidade. Nas configurações avaliadas, a utilização do GraphSAGE não demonstrou ganho relevante na detecção em relação ao escore de Mahalanobis calculado sobre os erros de persistência; a contribuição da estrutura em grafo observada na previsão de temperatura deve, portanto, ser distinguida do desempenho do detector de chuva forte. A validação com as séries reais do IAG-USP confirmou a plausibilidade física das estimativas do nó cego, com boa aderência diária (correlação de 0,73 a 0,87), embora superestime eventos convectivos localizados.

O escore de Mahalanobis não constitui, sozinho, um alerta antecipado: por depender do erro contra a observação em $t+h$, é detecção posterior, e sinaliza o evento em parte porque o modelo não o antecipa — mecanismo legítimo, mas que mistura anomalia meteorológica e limitação do preditor. A revocação de 100 % é diária e agregada na rede; por estação e janela de 60 minutos ela cai a cerca de 48 %, valor mais representativo do desempenho em uma perspectiva operacional. Os limiares p99 e p99,9 do escore, por serem percentis do próprio ano de teste, tornam a avaliação da detecção retrospectiva também quanto à calibração. Somam-se a topologia manual; a avaliação contra os próprios registros das estações, e não contra um cadastro oficial da Defesa Civil; a imputação bidirecional das lacunas, que preenche parte das células de entrada com leituras posteriores a t (Seção III-A); e a hipótese de homofilia, que eventos convectivos concentrados podem violar, como ilustra a superestimação do nó IAG-USP em 13 de janeiro. A utilização de um único ano de validação e de um único ano de teste limita a avaliação da robustez interanual. Os resultados não demonstram estabilidade de desempenho sob diferentes regimes climáticos, sendo necessária sua verificação em múltiplas divisões temporais com treinamento e calibração anteriores a

cada período de teste.

Os próximos passos seguem dessas limitações: janelas temporais mais longas, arquiteturas recorrentes ou de atenção, e fontes que carreguem a informação convectiva ausente (radar, descargas atmosféricas); o tratamento do reinício diário do contador dos pluviômetros, que no estudo de caso gera escores maiores que o próprio temporal; a validação dos alertas contra os registros da Defesa Civil e do CGE; a comparação da topologia manual com grafos por k vizinhos ou raio fixo; a harmonização das séries do INMET e a incorporação das do IAG-USP como âncoras; e a extensão da rede a novas estações, como as de um campus universitário (o da Universidade Presbiteriana Mackenzie), cenário de *Smart Campus* que motivou o projeto.

Disponibilidade de Código e Dados

O código que reproduz os experimentos, em Python com PyTorch Geometric, está disponível sob licença livre em https://github.com/viniolt/Previsao-Anomalias-Climaticas-GNN. Os dados de superfície são públicos, mantidos pelo CGE-SP.

Agradecimentos

Esta pesquisa foi realizada com o apoio do Fundo MackPesquisa através do processo nº 2024.FCI.SPP.0005, e implementada nas dependências do Laboratório MackLeaps. Os autores agradecem ao CNPq, pelo apoio por meio do PIBITI, e à Universidade Presbiteriana Mackenzie; e ao CGE-SP, ao IAG-USP e ao INMET, pela disponibilização dos dados meteorológicos.

Declaração sobre uso de Inteligência Artificial

Declara-se que ferramentas de Inteligência Artificial Generativa foram utilizadas neste trabalho: o assistente Claude (Anthropic) apoiou a redação e a revisão do texto, a formatação em LaTeX e a organização da revisão bibliográfica. Todo o conteúdo gerado foi revisado criticamente e validado pelos autores, que assumem integral responsabilidade pela originalidade e veracidade do texto final, em conformidade com a Portaria CNPq n° 2.664/2026.

Referências

[1] J. A. Marengo, T. Ambrizzi, L. M. Alves, N. J. C. Barreto, M. Simões Reboita, and A. M. Ramos, "Trends in extreme rainfall and hydrogeometeorological disasters in the Metropolitan Area of São Paulo: a review," *Ann. N. Y. Acad. Sci.*, vol. 1472, no. 1, pp. 5–20, 2020.

[2] S. I. Seneviratne, X. Zhang, M. Adnan *et al.*, "Weather and climate extreme events in a changing climate," in *Climate Change 2021: The Physical Science Basis. Contribution of WG I to the Sixth Assessment Report of the IPCC*. Cambridge: Cambridge University Press, 2021, ch. 11, pp. 1513–1766.

[3] P. Bauer, A. Thorpe, and G. Brunet, "The quiet revolution of numerical weather prediction," *Nature*, vol. 525, no. 7567, pp. 47–55, 2015.

[4] S. Ravuri, K. Lenc, M. Willson *et al.*, "Skilful precipitation nowcasting using deep generative models of radar," *Nature*, vol. 597, no. 7878, pp. 672–677, 2021.

[5] R. Lam, A. Sanchez-Gonzalez, M. Willson *et al.*, "Learning skillful medium-range global weather forecasting," *Science*, vol. 382, no. 6677, pp. 1416–1421, 2023.

[6] K. Bi, L. Xie, H. Zhang, X. Chen, X. Gu, and Q. Tian, "Accurate medium-range global weather forecasting with 3D neural networks," *Nature*, vol. 619, no. 7970, pp. 533–538, 2023.

[7] S. Salcedo-Sanz, J. Pérez-Aracil, G. Ascenso *et al.*, "Analysis, characterization, prediction, and attribution of extreme atmospheric events with machine learning and deep learning techniques: a review," *Theor. Appl. Climatol.*, vol. 155, pp. 1–44, 2024.

[8] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, Toulon, 2017.

[9] J. Gilmer, S. S. Schoenholz, P. F. Riley, O. Vinyals, and G. E. Dahl, "Neural message passing for quantum chemistry," in *Proc. Int. Conf. Mach. Learn. (ICML)*, Sydney, 2017, pp. 1263–1272.

[10] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang, and P. S. Yu, "A comprehensive survey on graph neural networks," *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 32, no. 1, pp. 4–24, 2021.

[11] W. L. Hamilton, R. Ying, and J. Leskovec, "Inductive representation learning on large graphs," in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, Long Beach, 2017, pp. 1024–1034.

[12] Z. Zamanzadeh Darban, G. I. Webb, S. Pan, C. C. Aggarwal, and M. Salehi, "Deep learning for time series anomaly detection: A survey," *ACM Comput. Surv.*, vol. 57, no. 1, pp. 15:1–15:42, 2024.

[13] Y. Li, R. Yu, C. Shahabi, and Y. Liu, "Diffusion convolutional recurrent neural network: Data-driven traffic forecasting," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, Vancouver, 2018.

[14] B. Yu, H. Yin, and Z. Zhu, "Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting," in *Proc. Int. Joint Conf. Artif. Intell. (IJCAI)*, Stockholm, 2018, pp. 3634–3640.

[15] R. Keisler, "Forecasting global weather with graph neural networks," arXiv:2202.07575, 2022.

[16] Q. Yang, J. Giezendanner, D. S. Civitarese, J. Jakubik, E. Schmitt, A. Chandra, J. Vila, D. Hohl, C. Hill, C. Watson, and S. Wang, "Local off-grid weather forecasting with multi-modal Earth observation data," arXiv:2410.12938, 2024.

[17] J. El-Shawa, E. Bagheri, S. Akinli Kocak, and Y. Mohsenzadeh, "A graph neural network approach for localized and high-resolution temperature forecasting," arXiv:2512.00546, 2025.

[18] Y. Wu, D. Zhuang, A. Labbe, and L. Sun, "Inductive graph neural networks for spatiotemporal kriging," in *Proc. AAAI Conf. Artif. Intell. (AAAI)*, vol. 35, 2021, pp. 4478–4485.

[19] E. Rossi, H. Kenlay, M. I. Gorinova, B. P. Chamberlain, X. Dong, and M. M. Bronstein, "On the unreasonable effectiveness of feature propagation in learning on graphs with missing node features," in *Proc. Learn. Graphs Conf. (LoG)*, 2022.

[20] NOAA Climate Prediction Center, "Oceanic Niño index (ONI), baseado no ERSSTv5," https://www.cpc.ncep.noaa.gov/data/indices/oni.ascii.txt, 2026, série histórica mensal (trimestres móveis). Acesso em: 24 set. 2026.

[21] R. W. Sinnott, "Virtues of the haversine," *Sky and Telescope*, vol. 68, no. 2, pp. 158–159, 1984.

[22] P. C. Mahalanobis, "On the generalised distance in statistics," *Proc. Nat. Inst. Sci. India*, vol. 2, no. 1, pp. 49–55, 1936.